

Phase 1 : Consolider le "Socle Engineering" (L'indispensable)

En Data Science, on écrit du code pour explorer. En Engineering, on écrit du code pour qu'il tourne tout seul, sans erreur, à grande échelle.

- **Python Avancé** : Sortir des notebooks Jupyter. Apprends la Programmation Orientée Objet (POO), les décorateurs, et la gestion des environnements virtuels (venv, poetry).
- **Clean Code & Git** : Maîtriser le versioning (branches, merge requests, CI/CD de base). Apprends les principes **SOLID** pour que mon code soit maintenable.
- **SQL Avancé** : pas me contenter de SELECT*. Apprendre les fonctions de fenêtrage (WINDOW functions), les CTE (Common Table Expressions) et l'optimisation de requêtes.
- **Docker** : C'est la base. Je dois savoir "conteneuriser" ton modèle pour qu'il tourne de la même manière sur mon PC et sur un serveur.

Phase 2 : Data Engineering (Le transport de la donnée)

C'est ici que je vais apprendre à construire les tuyaux qui vont alimenter tes modèles.

- **Architecture des données** : Maîtrise la différence pratique entre **Data Lake** (Amazon S3, Azure Data Lake) et **Data Warehouse** (Snowflake, BigQuery).
- **Outils d'Orchestration** : Apprends à planifier tes tâches. Le standard du marché est **Apache Airflow** (ou Prefect).
- **Le Big Data** : Apprends **PySpark**. Même si tu ne l'utilises pas tous les jours, tu dois savoir manipuler des données qui ne tiennent pas dans la RAM de ton ordinateur.
- **Transformation (dbt)** : Apprends l'outil **dbt** (data build tool), qui est devenu le standard pour transformer les données à l'intérieur d'un Data Warehouse.

Phase 3 : MLOps (Le pont entre les deux mondes)

C'est le sommet de mon profil hybride : automatiser le cycle de vie d'un modèle.

- **Tracking d'expériences** : Utilise **MLflow** ou Weights & Biases pour suivre mes métriques, mes paramètres et mes versions de modèles.
- **Déploiement d'API** : Apprends à exposer mon modèle via une API avec **FastAPI** ou Flask.
- **Monitoring** : Comment savoir si mon modèle devient moins performant avec le temps ? Apprends à surveiller le "Data Drift".

- **Cloud (AWS, Azure ou GCP)** : Choisis-en un et passe une certification de base (ex: AWS Certified Cloud Practitioner). Le Cloud est le terrain de jeu principal du Data Engineer.